Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н. Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н. Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Программное обеспечение ЭВМ и информационные технологии»

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

НА ТЕМУ:

«Методы генерации текста»

Студент ИУ7-52Б (Группа) _____ (Подпись, дата) Новиков А. А. (И. О. Фамилия)

Руководитель НИР _____ (Подпись, дата) Кострицкий А. С. (И. О. Фамилия)

2024 г.

Задание

РЕФЕРАТ

Расчетно-пояснительная записка 17 страниц, 4 рисунка, 1 таблица, 9 источников, 1 приложение. Объектом исследования являются методы генерации текста.

Цель работы — провести обзор и сравнить существующие методы генерации текста.

В процессе работы были рассмотрены существующие методы генерации текста и был проведен их сравнительный анализ.

СОДЕРЖАНИЕ

РЕФЕРАТ **3**

ВВЕДЕНИЕ **5**

1 Аналитический раздел **6**

1.1 Основные вехи развития 6

1.2 Генерация на основе шаблонов 7

1.3 N-граммные модели 7

1.4 Скрытые марковские модели 8

1.5 Рекуррентные нейронные сети 9

1.6 Сети долговременной кратковременной памяти 10

1.7 Трансформеры 12

1.8 Критерии сравнения 12

ЗАКЛЮЧЕНИЕ **15**

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ **16**

ПРИЛОЖЕНИЕ А **17**

ВВЕДЕНИЕ

Генерация текста является одной из ключевых задач в области обработки естественного языка, которая активно развивается благодаря достижениям в машинном обучении и увеличению объемов доступных данных. Автоматизированные системы генерации текста находят широкое применение в различных сферах, таких как создание контента, автоматизация общения с пользователями и анализ данных.

Целью данной работы является анализ существующих методов генерации текста, применяемых для создания осмысленного и грамматически правильного текста на русском языке. Для достижения этой цели необходимо решить следующие задачи:

— Обозначить основные вехи развития;

— Формализовать задачу генерации текста;

— Перечислить методы решения задачи генерации текста;

— Сравнить перечисленные методы.

1 Аналитический раздел

На рисунке 1.1 представлена формализация задачи генерации текста в виде диаграммы IDEF0.

Рисунок 1.1 – Формализация задачи в виде IDEF0

1.1 Основные вехи развития

История генерации текста началась в 1950-х годах с первых статистических методов, таких как N-граммы, которые оценивали вероятность появления слова на основе предыдущих слов [1]. Однако эти методы имели ограничение по размеру контекста, что мешало учитывать дальние зависимости в тексте.

В 1980-х и 1990-х годах появились более сложные подходы, которые сочетали статистические методы и правила. Эти методы использовали частоты слов и грамматический анализ для генерации текста. Модели на основе правил полагались на лингвистические правила, написанные вручную экспертами. Хотя это позволяло учитывать грамматику и смысл, процесс был трудоемким и не всегда мог справиться с разнообразием естественного языка. В это время также развивались скрытые марковские модели [2].

С начала 2000-х годов рекуррентные нейронные сети (РНС) и модели с долгой краткосрочной памятью (LSTM) значительно улучшили генерацию текста. LSTM особенно хорошо справлялись с задачами, требующими учета долговременных зависимостей.

Современный этап развития начался с появления архитектуры трансформеров в 2017 году [3]. Эта архитектура позволяет моделям учитывать

важные части текста и устанавливать сложные зависимости между словами, независимо от их расстояния. Трансформеры также более эффективны, так как могут обрабатывать текст параллельно, что сокращает время обучения.

1.2 Генерация на основе шаблонов

Метод генерации текста на основе шаблонов — это один из самых простых и интуитивно понятных подходов к созданию текстовой информации. Он основан на использовании заранее определенных структурированных шаблонов, в которые подставляются переменные элементы, такие как слова или фразы. Этот метод широко применяется в различных областях, включая автоматизацию отчетности, создание новостных статей и генерацию ответов простых чат-ботов.

1.3 N-граммные модели

N-граммные модели являются одним из основных методов в области обработки естественного языка для статистического моделирования последовательностей текста. Они основываются на предположении, что появление слова в предложении зависит только от $N-1$ предыдущих слов. При таком подходе значительно упрощается задача моделирования языка, позволяя решить ее с использованием вероятностных методов.

N-грамма — последовательность из N элементов. В зависимости от значения N выделяют различные типы моделей: биграммы, триграммы и т.д. Рассмотри модель для $N = 2$. Пусть $w_1, w_2, w_3, ..., w_n$ - это последовательность слов. Тогда вероятность появления слова w_n в контексте предыдущего слова w_{n-1} может быть посчитана как условная вероятность по формуле 1.1:

$$P(w_n|w_1, w_2, ..., w_{n-1}) \approx P(w_n|w_{n-1}) = \frac{P(w_n, w_{n-1})}{P(w_{n-1})} = \frac{count(w_n, w_{n-1})}{count(w_{n-1})} \quad (1.1)$$

Для биграмм на каждом шаге мы учитываем только предыдущее слово и основываем свой выбор только на нем. Но при использовании такого подхода качество текста будет низким, поэтому логично будет увеличить количество рассматриваемых слов на каждом шаге. В общем виде вероятность появления слова w_n в контексте предыдущих w_{n-1} слов при анализе N слов можно

посчитать по формуле 1.2:

$$P(w_n|w_1, w_2, ..., w_{n-1}) \approx P(w_n|w_{n-N}, w_{n-N+1}, ..., w_{n-1}) \tag{1.2}$$

Чем больше значение N, тем более детализированной будет модель. В то же время, чем длиннее рассматриваемая цепочка, тем меньше различных вариаций употребления отдельно взятого слова, то есть при построении модели на небольших корпусах сгенерированный текст становится менее разнообразным и будет чаще повторять оригинал.

N-граммные модели достаточно просты для реализации и понимания, они подходят для создания простых текстов, а также для анализа существующего текста. Однако данные модели зачистят от размера N и чувствительны к разреженным данным: при увеличении размера учитываемых слов N увеличивается количество параметров, которые необходимо оценить, также в реальных языках многие возможные последовательности слов могут никогда не встретиться, что приводит к проблеме разреженности.

1.4 Скрытые марковские модели

Скрытые марковские модели (СММ) представляют собой статистические модели, которые предполагают наличие скрытого состояния, определяющего наблюдаемые события. В контексте генерации текста СММ могут использоваться для предсказания следующего слова или символа на основе предыдущих слов.

На рисунке 1.2 изображена диаграмма переходов в скрытой марковской модели. Модель состоит из следующих элементов:

— Набора скрытых состояний $H = (h_1, h_2, ..., h_N)$. Данные состояния представляют собой латентные переменные, которые описывают структуру последовательности. В случае текстовой генерации скрытые состояния могут быть частями речи;

— Наблюдаемые символы $O = (o_1, o_2, ..., o_N)$. Непосредственно наблюдаемые элементы последовательности, например, слова;

— Матрица переходов $A = P(h_{t+1}|h_t)$. Вероятности перехода между скрытыми состояниями;

— Матрица эмиссий ($B = P(o_t|h_t)$). Вероятность генерации наблюдаемых символов из скрытых состояний.

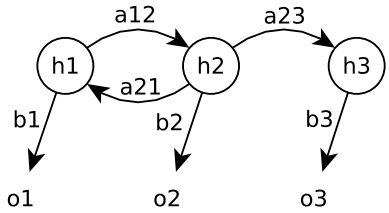

Рисунок 1.2 – Диаграмма переходов в скрытой марковской модели

Скрытая марковская модель основывается на марковском свойстве, которое предполагает, что текущее состояние зависит только от предыдущего состояния, а наблюдаемые данные зависят только от текущего состояния [2].

Благодаря разделению скрытой структуры и наблюдаемой последовательности, скрытые марковские модели позволяют генерировать более правдоподобный текст, однако ограниченность контекста и низкая выразительность часто сужает их применение в сложных языковых моделях.

1.5 Рекуррентные нейронные сети

В традиционных нейронных сетях входы и выходы обрабатываются независимо. Однако такие задачи, как предсказание следующего слова в предложении, требуют информации о предыдущих словах для точных предсказаний. Чтобы обойти это ограничение, были разработаны рекуррентные нейронные сети (РНС) [4].

Рекуррентные нейронные сети представляют механизм, в котором выход одного шага возвращается в качестве входа для следующего, что позволяет им сохранять информацию из предыдущих выходов. Такая конструкция делает РНС хорошо подходящими для задач, где контекст из предыдущих шагов имеет важное значение, а именно для прогнозирования следующего слова в предложении.

Определяющей особенностью РНС является их скрытое состояние, также называемое состоянием памяти, которое сохраняет важную информацию из предыдущих выходов последовательности. Используя одни и те же параметры на всех этапах, РНС работают последовательно на входах, снижая

сложность параметров по сравнению с традиционными нейронными сетями. Эта возможность делает РНС высокоэффективными для последовательных задач.

На рисунке 1.3 показано, что РНС разворачивается в полную сеть. Развертка описывает сеть для полной последовательности. Например, если последовательность представляет собой предложение из 5 слов, развертка будет состоять из 5 слоев: по слою на каждое слово.

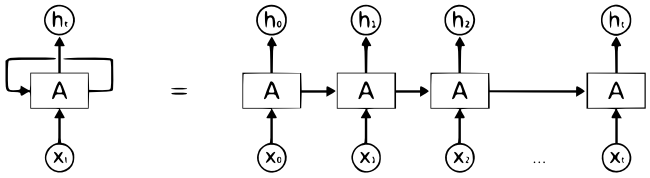

Рисунок 1.3 – Рекуррентная нейронная сеть и ее развертка

На каждом шаге скрытое состояние обновляется по формуле 1.3:

$$s_t = f(W_x x_t + W_s s_{t-1} + b), \tag{1.3}$$

где W_x, W_s - веса отвечающие за обработку текущего входа и за связь с предыдущим состоянием соответственно, b - смещение, f - функция активации.

Обучение РНС происходит аналогично обучению обычной нейронной сети. Используется алгоритм обратного распространения ошибки, но поскольку одни и те же параметры используются на всех временных этапах в сети, градиент на каждом шаге зависит не только от расчетов текущего шага, но и от предыдущих временных шагов.

Классическая форма РНС состоит из одного скрытого слоя, где веса определяются по временным шагам. Такие модели подходят для обучения коротким зависимостям, но ограничены проблемой затухающего градиента, из-за которой модель сложно оценивает взаимосвязь между удаленными словами в последовательности.

1.6 Сети долговременной кратковременной памяти

LSTM (*long short-term memory*) — тип рекуррентной нейронной сети, специально разработанный для устранения проблемы долгосрочной зависимости, вводя ячейку памяти, которая является контейнером способным хранить информацию в течение длительного периода времени [5].

В отличие от стандартных рекуррентных нейронных сетей, в которых повторяющийся модуль имеет простую структуру, LSTM-модуль состоит из четырех взаимодействующих компонентов. На рисунке 1.4 представлена схема слоев долго-краткосрочной памяти.

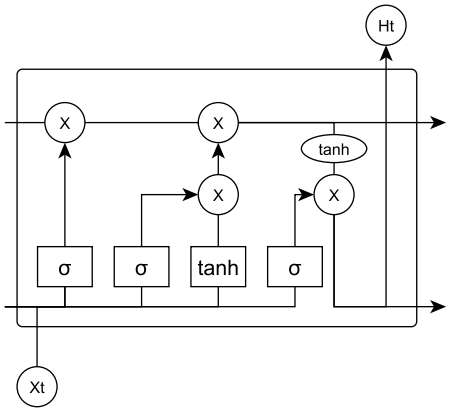

Рисунок 1.4 – Схема слоев долго-краткосрочной памяти

Ключевым понятием LSTM является состояние ячейки, которое является подобием памяти сети, которая предает информацию по всей цепочке модулей.

В процессе обучения состояние ячейки изменяется: добавляется новая или удаляется старая информация. За обновление памяти отвечают структуры, называемые фильтрами. Фильтры состоят из слоя сигмоидальной нейронной сети и операции поточечного умножения. Сигмоидальный слой возвращает число от 0 до 1, которое обозначает, какую часть информации необходимо пропустить дальше по сети [6].

Существует три основных фильтра, контролирующих состояние ячейки:

— Фильтр забывания — фильтр, который определяет, какая информация больше не нужна состоянию ячейки, а какую информацию оставить.

— Входной фильтр определяет, какую информацию требуется добавить к состоянию ячейки. Сначала с помощью сигмоидальный функции определяется, какие значения требуется обновить. Затем с помощью функции tanh строится вектор новых значений-кандидатов.

— Выходной фильтр извлекает полезную информацию из текущего состояния ячейки для предоставления ее в качестве выходных данных. В конце перемножаются значения текущего входа и предыдущего выхо-

да, пропущенные через сигмоидальный слой, с текущим состоянием, пропущенным через функцию tanh.

1.7 Трансформеры

Трансформеры представляют собой одну из самых значимых разработок в области обработки естественного языка, основанную на использовании механизма самовнимания и параллельной обработки данных. Данная архитектура устранила множество ограничений, присущих рекуррентным нейронным сетям: невозможность эффективного моделирования дальнодействующих зависимостей и последовательный характер обработки данных, не позволяющий осуществлять параллельную работу с данными.

Основой трансформеров является механизм самовнимания, который позволяет модели эффективно учитывать взаимосвязи между всеми элементами последовательности, независимо от их относительного положения. Благодаря этому трансформеры способны выявлять сложные зависимости в тексте. Механизм внимания для каждого элемента последовательности определяет, какие другие элементы последовательности необходимы для его понимания в данном контексте [7].

Архитектура трансформеров включает два основных компонента: энкодер и декодер. Энкодер преобразует входную последовательность в набор векторных представлений, которые содержат информацию о взаимосвязях между элементами текста. Декодер, в свою очередь, использует эти представления для генерации текста, основываясь на предшествующем контексте [8].

1.8 Критерии сравнения

Задача генерации текста на естественном языке решается различными методами, для оценки которых необходимо сформировать критерии, по которым можно оценить их эффективность и применимость.

Изучив существующие методы генерации текста, можно выделить следующие критерии сравнения:

— Качество текста. Способен ли метод генерировать логически связный текст;

— Учет контекста. Количество учитываемых токенов последовательности при обработке текущего токена [9];

— Гибкость и разнообразность. Способен ли метод генерировать разнообразные тексты;

В таблице 1.1 представлено обобщенное сравнение рассмотренных методов.

Таблица 1.1 – Сравнения методов генерации текста

	Качество текста	**Учет контекста**	**Гибкость**
Шаблоны	+	Отсутствует	−
N-граммы	−	N предыдущих токенов	−
СММ	−	1 предыдущий токен	−
РНС	+	Менее 10 токенов	+
LTSM	+	Десятки токенов	+
Трансформеры	+	Все токены	+

Использование шаблонов позволяет создавать грамматически правильный текст без необходимости в обучении, однако генерируемый текст ограничен заданными параметрами шаблона, поэтому не обладает высокой оригинальностью.

Использование N-граммных моделей и скрытых марковских моделей позволяет создавать более разнообразный текст, но такие модели сильно зависят от входных данных и чувствительны к разреженным данным. Также контекст, который способны обрабатывать данные модели сильно ограничен: N-граммные модели ограничены размером N, СММ - предыдущим состоянием.

Рекуррентные нейронные сети способны моделировать сложные зависимости с учетом предыдущих состояний, однако такие модели уже требуют большего объема данных и вычислительных мощностей, также при их использовании наблюдается проблема затухания градиентов, из-за чего

LSTM-модели решают основную проблему РНС. Они применимы в широком спектре задач, способны генерировать сложные логические зависимости, благодаря работе с долговременными зависимостями.

Трансформеры являются самым мощным инструментом генерации текста. Они способны создавать разнообразный текст под любые задачи. Хотя они требуют большого объема данных для обучения, сам процесс может быть произведен параллельно, а не последовательно, как в РНС и LSTM-моделях.

ЗАКЛЮЧЕНИЕ

Для решения задачи генерации текста на данный момент наилучшим вариантом является архитектура трансформеров, однако данная модель может быть избыточной для тривиальных задач, потому что использует высокие вычислительные мощности и требует большого объема обучающих данных.

В ходе выполнения данной научно-исследовательской работы были решены следующие задачи:

— Обозначены основные вехи развития методов генерации текста;

— Формализована задача генерации текста;

— Перечислены методы решения задачи генерации текста;

— Произведено сравнение рассмотренных методов.

В рамках работы были выполнены все поставленные задачи. Цель работы была достигнута.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *Shannon C. E.* A mathematical theory of communication // The Bell system technical journal. — 1948. — Т. 27, № 3. — С. 379—423.
2. *Rabiner L. R.* A tutorial on hidden Markov models and selected applications in speech recognition // Proceedings of the IEEE. — 1989. — Т. 77, № 2. — С. 257—286.
3. *Vaswani A.* Attention is all you need // Advances in Neural Information Processing Systems. — 2017.
4. *Созыкин А. В.* Обзор методов обучения глубоких нейронных сетей // Вестник Южно-Уральского государственного университета. Серия: Вычислительная математика и информатика. — 2017. — Т. 6, № 3. — С. 28—59.
5. *Хамидов Э. Х.*, *Собиров М. М.*, *Ходжиматов М. М.* НЕЙРОННЫЕ СЕТИ RNN И LSTM // Journal of new century innovations. — 2022. — Т. 11, № 1. — С. 127—135.
6. *Соснин А. С.*, *Суслова И. А.* Функции активации нейросети: сигмоида, линейная, ступенчатая, relu, tahn // ББК Ч402. — 2019. — С. 237.
7. Transformer in transformer / K. Han [и др.] // Advances in neural information processing systems. — 2021. — Т. 34. — С. 15908—15919.
8. A survey on vision transformer / K. Han [и др.] // IEEE transactions on pattern analysis and machine intelligence. — 2022. — Т. 45, № 1. — С. 87—110.
9. Модели генеративного искусственного интеллекта с полным их разоблачением [Электронный ресурс]. — URL: `https://www.unkniga.ru/ai/modeli-generativnogo-iskusstvennogo-intellekta-s-polnym-ikh-razoblacheniem.html` (дата обращения 19.12.2024).

ПРИЛОЖЕНИЕ А

Презентация к научно-исследовательской работе состоит из 3 слайдов.