Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н. Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н. Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Программное обеспечение ЭВМ и информационные технологии»

ОТЧЕТ

ПО НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

НА ТЕМУ:

«»

Студент А. А. Новиков/ИУ7-72Б
(Группа)

(Подпись, дата)

О. В. Кузнецова
(И. О. Фамилия)

Руководитель НИР

(Подпись, дата)

(И. О. Фамилия)

2025 г.

Задание

РЕФЕРАТ

Расчетно-пояснительная записка n страниц, n рисунка, n таблица, n источников, n приложение.

СОДЕРЖАНИЕ

РЕФЕРАТ **3**

ВВЕДЕНИЕ **5**

1 Аналитический раздел **6**

1.1 Предметная область 6

1.2 Меры расстояний 6

ЗАКЛЮЧЕНИЕ **11**

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ **12**

ПРИЛОЖЕНИЕ А **13**

ВВЕДЕНИЕ

Целью данной работы ... . Для достижения этой цели необходимо решить следующие задачи:

—

—

—

—

1 Аналитический раздел

1.1 Предметная область

Кластеризация или кластерный анализ [1] — это задача разбиения множества объектов на группы, называемые кластерами. При этом внутри каждой группы должны оказаться похожие объекты, а объекты разных групп должны быть как можно более отличны. Основным отличием кластеризации от классификации состоит в том, что перечень групп четко не задан и определяется в процессе работы алгоритма.

Данные, с которыми работают методы кластеризации, по виду можно подразделить на числовые и категориальные.

Числовые данные [2] — это данные, характеризующие состояние какого-либо параметра изучаемого объекта. Наиболее часто такие данные бывают представлены вещественными числами. Примерами числовых данных являются цена товара, вес человека, атмосферное давление, скорость автомобиля.

Категориальные данные [2] — это данные, образующие признак принадлежности к какой-либо группе. Примерами категориальных данных являются цвет автомобиля, уровень образования человека.

1.2 Меры расстояний

Одним из важнейших аспектов кластеризации данных является выбор меры расстояния [3], которая определяет степень сходства или различия двух объектов.

Мерой расстояния между двумя объектами $d(x, y)$ называется неотрицательная функция, удовлетворяющая следующим правилам:

$$\begin{cases} d(x,y) \geq 0 \\ d(x,y) = d(y,x) \\ d(x,y) = 0 \iff x = y \\ d(x,y) \leq d(x,u) + d(u,y) \end{cases}, \tag{1.1}$$

где x, y, u — любые объекты кластерного анализа.

Мера расстояния может существенно повлиять на конечный результат кластеризации. Выбор меры расстояний в кластеризации должен осуществляться в зависимости от решаемой задачи и от типа данных.

Евклидово расстояние

Евклидово расстояние — наиболее широко используемая мера расстояний в кластеризации. Представляет собой расстояние между двумя точками в многомерном пространстве. Формула для евклидова расстояния:

$$d(x, y) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}, \tag{1.2}$$

где x_i, y_i — координаты точек x, y соответственно в n-мерном пространстве.

Не смотря на свою простоту, евклидово расстояние имеет ряд недостатков. Оно не инвариантно к масштабу, что вынуждает проводить нормализацию перед его использованием. А также с увеличением размерности становится менее предсказуемым [4]. Однако оно все также применимо для числовых данных.

Квадрат евклидова расстояния

Квадрат евклидова расстояния используется для придания большего веса более отдаленным друг от друга объектам. Вычисляется данное расстояние по следующей формуле:

$$d(x, y) = \sum_{i=1}^{n} (x_i - y_i)^2, \tag{1.3}$$

где x_i, y_i — координаты точек x, y соответственно в n-мерном пространстве.

Квадрат евклидова расстояния позволяет подчеркнуть различия между объектами. Также оно ускоряет вычисления и менее чувствительно к выбросам. Но при большом различии между объектами эта метрика может привести к потери точности. Также как и евклидово расстояние квадрат евклидова расстояния подходит только для численных данных.

Манхэттенское расстояние

Манхэттенское расстояние (расстояние городских кварталов) — это сумма абсолютных разностей между декартовыми координатами точек. Высчитывается по формуле:

$$d(x, y) = \sum_{i=1}^{n} |x_i - y_i|, \tag{1.4}$$

где x_i, y_i — координаты точек x, y соответственно в n-мерном пространстве.

Название получено из-за особенности перемещения по городским кварталам, в которых единственными доступными направлениями являются вертикальное и горизонтальное.

Манхэттенское расстояние предпочтительнее при высокой размерности данных и оно более устойчиво к выбросам [5]. Для работы с категориальными данными данная метрика не подходит.

Расстояние Минковского

Расстояние Минковского — это обобщенная форма евклидова и манхэттенского расстояний. Расстояние Минковского порядка p вычисляется по формуле:

$$d(x, y) = (\sum_{i=1}^{n} |x_i - y_i|^p)^{\frac{1}{p}}, p \geq 1, \tag{1.5}$$

где x_i, y_i — координаты точек x, y соответственно в n-мерном пространстве, p — параметр, определяющий взаимодействие между признаками.

При $p = 1$ формула 1.5 принимает вид Манхеттоновского расстояния, при $p = 2$ — расстояния Евклида.

Расстояние Минковского наследует недостатки метрик, которые оно обобщает. Наличие параметра p позволяет гибко управлять поведением метрики и выбирать оптимальное значение для конкретной задачи, однако подбор подходящего параметра может оказаться вычислительно затратным и требовать дополнительного анализа данных.

Степенное расстояние

Расстояние Чебышева

Расстояние Чебышева определяется как наибольшая разность двух векторов по любой координатной оси. Другими словами, это просто максимальное расстояние по одной оси. Для нахождения расстояния Чебышева используется следующая формула:

$$d(x, y) = \max_{i=1}^{n} |x_i - y_i|, \tag{1.6}$$

где x_i, y_i — координаты точек x, y соответственно в n-мерном пространстве.

Расстояние Хэмминга

Расстояние Хэмминга — это число позиций, различающихся между двумя векторами. Обычно его используют для сравнения двух двоичных строк одинаковой длины. Для двух векторов $\vec{x}$, $\vec{y}$ размерности n расстояние Хэмминга вычисляется по формуле:

$$d(\vec{x}, \vec{y}) = \sum_{i=1}^{n} \delta(x_i, y_i), \tag{1.7}$$

где

$$\delta(x_i, y_i) = \begin{cases} 0, & \text{если } x_i = y_i, \\ 1, & \text{если } x_i \neq y_i. \end{cases} \tag{1.8}$$

Расстояние Жаккара

Расстояние Жаккара используется для измерения степени различия между двумя множествами. Формула для вычисления расстояния Жаккара имеет вид:

$$d(x, y) = 1 - \frac{|x \cap y|}{|x \cup y|}, \tag{1.9}$$

где $|x \cap y|$ — количество общих признаков между объектами x и y, а $|x \cup y|$ — количество признаков, присутствующих хотя бы в одном из них.

Таким образом, расстояние Жаккара показывает, насколько объекты раз-

личаются относительно общего числа признаков. Чем больше доля совпадающих признаков, тем меньше значение расстояния.

Метрика Жаккара хорошо подходит для категориальных, однако она чувствительна к разреженности данных — при большом числе нулевых признаков схожие объекты могут иметь заниженное сходство.

Расстояние Гауэра

Расстояние Гауэра — обобщенная метрика, применимая для сравнения объектов как с числовыми признаками, так и с категориальными. Общая формула расстояния Гауэра имеет вид:

$$d(x, y) = \frac{1}{n} \sum_{i=1}^{n} s_i(x_i, y_i), \tag{1.10}$$

где n — количество признаков, а $s_i(x_i, y_i)$ — расстояние между i-ми признаками объектов x и y.

Для числовых признаков расстояние вычисляется по формуле:

$$s_i = \frac{|x_i - y_i|}{R_i}, \tag{1.11}$$

где R_i диапазон значений i-ого признака.

Для категориальных признаков расстояние вычисляется по формуле:

$$s_i = \begin{cases} 0, & \text{если } x_i = y_i, \\ 1, & \text{иначе.} \end{cases} \tag{1.12}$$

Расстояние Гауэра эффективно при работе с объектами, содержащими разные типы признаков. Его основным преимуществом является универсальность, так как метрика позволяет обрабатывать как числовые, так и категориальные данные. Однако при большом количестве категориальных признаков вклад числовых признаков может снижаться из-за нормализации, что приводит к уменьшению чувствительности метрики к числовым различиям.

ЗАКЛЮЧЕНИЕ

В ходе выполнения данной научно-исследовательской работы были решены следующие задачи:

—

—

—

—

В рамках работы были выполнены все поставленные задачи. Цель работы была достигнута.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *Ершов К.*, *Романова Т.* Анализ и классификация алгоритмов кластеризации // Новые информационные технологии в автоматизированных системах. — 2016. — № 19. — С. 274—279.

2. Анализ данных / М. А. Поручиков [и др.] // Самара: Изд-во Самар. ун-та. — 2016.

3. *Гитис Л.* Статистическая классификация и кластерный анализ. — ЛитРес, 2017.

4. *Aggarwal C. C.*, *Hinneburg A.*, *Keim D. A.* On the surprising behavior of distance metrics in high dimensional space // International conference on database theory. — Springer. 2001. — С. 420—434.

5. *Mohibullah M.*, *Hossain M. Z.*, *Hasan M.* Comparison of euclidean distance function and manhattan distance function using k-mediods // International Journal of Computer Science and Information Security (IJCSIS). — 2015. — Т. 13, № 10. — С. 61—71.

ПРИЛОЖЕНИЕ А

Презентация к научно-исследовательской работе состоит из 3 слайдов.